

**TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN**



BÁO CÁO ĐỒ ÁN MÔN PHÂN TÍCH XỬ LÝ ẢNH

ĐỀ TÀI:

**Nhận diện ảnh tạo sinh: Hướng tiếp cận kết
hợp mô hình VOLO và phương pháp HAT**

Giảng viên hướng dẫn:

PGS.TS. PHẠM THẾ BẢO

Sinh viên nhóm 13 thực hiện:

NGUYỄN TOÀN THẮNG – 3123410343

DƯƠNG TÙNG THIỆN - 3123410350

HỒ MINH TIẾN - 3123410373

ĐẶNG THÁI TÚ - 3123410399

TP. Hồ Chí Minh, 2026

LỜI CẢM ƠN

Trước hết, chúng em xin gửi lời cảm ơn chân thành đến Ban Giám hiệu Trường Đại học Sài Gòn và toàn thể quý thầy cô Khoa Công nghệ Thông tin đã tận tình giảng dạy, truyền đạt những kiến thức quý báu trong suốt quá trình học tập.

Đặc biệt, chúng em xin bày tỏ lòng biết ơn sâu sắc đến giảng viên hướng dẫn PGS.TS. Phạm Thế Bảo, người đã trực tiếp hướng dẫn, góp ý và định hướng cho em trong suốt quá trình thực hiện đề án. Những ý kiến đóng góp của thầy đã giúp em hoàn thiện đề tài một cách tốt hơn cả về nội dung lẫn phương pháp nghiên cứu.

Mặc dù đã cố gắng hết sức, nhưng do hạn chế về thời gian và kinh nghiệm, đề án không tránh khỏi những thiếu sót. Nhóm rất mong nhận được sự thông cảm và những ý kiến đóng góp quý báu từ thầy cô để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!

Tập thể nhóm 13

Nhận diện ảnh tạo sinh: Hướng tiếp cận kết hợp mô hình VOLO và phương pháp HAT

Dương Tùng Thiện^a, Nguyễn Toàn Thắng^{a,*}, Hồ Minh Tiến^a, Đặng Thái Tú^a

^aTrường Đại học Sài Gòn, 273 An Dương Vương, Phường Chợ Quán, TP.Hồ Chí Minh, Việt Nam

Abstract. Sự phát triển mạnh mẽ của AI tạo sinh hình ảnh đã mang lại nhiều ứng dụng thực tiễn nhưng đồng thời dấy lên những lo ngại sâu sắc về vấn đề tin giả và vi phạm bản quyền. Mặc dù các mô hình nhận diện dựa trên nền tảng Vision Transformer (ViT) đang cho thấy hiệu năng cao, chúng vẫn bộc lộ điểm yếu trong việc nắm bắt các dấu vết bất thường (artifacts) tại dải tần số cao. Để giải quyết thách thức này, nghiên cứu đề xuất một hướng tiếp cận mới: kết hợp kiến trúc mô hình VOLO (Visual Outlooker for Image Recognition) với phương pháp huấn luyện đối kháng tần số cao (HAT) nhằm tối ưu hóa khả năng trích xuất đặc trưng cục bộ và đặc trưng miền tần số. Quá trình thực nghiệm được tiến hành thông qua việc tinh chỉnh mô hình trên tập dữ liệu MS COCOAI kết hợp cùng hàm mất mát Focal Loss nhằm khắc phục triệt để bài toán mất cân bằng dữ liệu. Kết quả phân loại cho thấy mô hình đạt độ chính xác khả quan ở mức 81,31% trên tập kiểm tra cùng phân phối, tuy nhiên hiệu suất lại giảm đáng kể xuống mức 59,86% khi đối mặt với tập dữ liệu Chameleon, chứa những artifacts mà mô hình chưa được học. Thông qua các phân tích chuyên sâu bằng phổ FFT và công cụ Grad-CAM, nghiên cứu chỉ ra rằng sự sụt giảm này xuất phát từ việc mô hình còn thiếu nhất quán trong định vị đặc trưng, từ đó khẳng định việc nâng cao khả năng tổng quát hóa sẽ là mục tiêu trọng tâm cho các nghiên cứu tương lai.

Keywords: Nhận diện ảnh tạo sinh, Vision Transformer, VOLO, Huấn luyện đối kháng tần số cao (HAT), Grad-CAM, Khả năng tổng quát hóa.

*Nguyễn Toàn Thắng, nguyentoanthang15122005@gmail.com

1 Giới thiệu

Thuật ngữ “AI tạo sinh” được phổ biến kể từ năm 2022, các mô hình ấy đã chứng minh được tầm quan trọng của mình thông qua những đóng góp đẩy mạnh năng suất của con người [1]. Đã có nhiều biến thể của AI tạo sinh được phát triển để hỗ trợ con người trong các lĩnh vực khác nhau, trong đó có lĩnh vực thiết kế và mỹ thuật thông qua sự ra đời của các AI tạo sinh hình ảnh (Artificial Intelligence Generated Image - AIGI). Điều này đã giúp ích cho nhiều người nhưng cũng tạo ra nhiều lo ngại khác, trong số đó có liên quan đến vấn đề tin giả [2] và vấn đề về bản quyền [3]. Những lo ngại có căn cứ đó đã thúc đẩy việc cần có những công cụ nhằm nhận diện được hình ảnh do AI tạo ra (AIGI detectors), với mục tiêu giảm thiểu vấn đề tin giả, cũng như gạt bỏ sự bất công của các nghệ sĩ trong việc bị vi phạm bản quyền các sáng tác nghệ thuật của mình. Tuy nhiên, việc nhận diện nội dung tạo sinh vẫn còn gặp nhiều khó khăn, khi cả hai đều đang phát triển để có thể thực hiện công việc của mình tốt hơn, việc tạo ra AIGI detector với độ chính xác gần như tuyệt đối là điều khó xảy ra [4]. Ngoài bài toán về độ chính xác, một thách thức lớn hơn là khả năng tổng

quát hóa (Generalization) — liệu AIGI detectors có nhận diện được ảnh từ các công cụ tạo ảnh AI chưa từng thấy?

Trong bài báo này, chúng tôi tiến hành sử dụng kiến trúc mô hình tối ưu hơn trong việc nhận diện ảnh AI, cụ thể nhóm đã tìm hiểu và đóng góp được những thông tin sau:

- AIGI detectors vẫn còn gặp rất nhiều khó khăn trong việc nhận diện chính xác tuyệt đối là vì chúng không được thiết kế để có thể nhận diện những artifacts ở dải tần số cao của AIGI một cách tối ưu ([Phần 2](#)).
- Đề xuất hướng tiếp cận tối ưu hơn: Ứng dụng mô hình VOLO - Visual Outlooker for Image Recognition [\[5\]](#) kết hợp với phương pháp huấn luyện HAT - High-frequency Adversarial Training [\[6\]](#) để mô hình có thể nhận diện artifact của các AIGIs một cách tốt hơn ([Phần 3](#)).
- Thiết lập thực nghiệm: Sử dụng mô hình VOLO, huấn luyện bằng phương pháp HAT trên tập dữ liệu MS COCOAI [\[7\]](#) và MS COCO [\[8\]](#) để cân bằng dữ liệu giữa tập ảnh thật và ảnh AI ([Phần 4](#)).
- Tiến hành so sánh, phân tích kết quả của mô hình khi kiểm trên tập test của hai loại tập dữ liệu: MS COCOAI và Chameleon [\[9\]](#) nhằm kiểm tra khả năng tổng quát hóa của mô hình. Phân tích phổ tần số giữa ảnh thật và ảnh giả của các tập dữ liệu và áp dụng kỹ thuật Grad-CAM [\[10\]](#) để lý giải khả năng dự đoán của mô hình ([Phần 6](#)).

Chúng tôi sử dụng mô hình VOLO thay vì những mô hình biến thể ViT phổ biến hơn (e.g.: Swin Transformer [\[11\]](#)) là vì độ tối ưu của mô hình trong việc trích xuất các đặc trưng cục bộ, và nắm bắt tín hiệu tần số cao tốt hơn, điều này sẽ được thể hiện ở [phần ba](#) của bài báo. Thông qua những khám phá của nhóm, nhóm đã đóng góp được những góc nhìn thú vị cho công cuộc nhận diện ảnh AI, cũng như giúp người đọc có cái nhìn tổng quan về công cuộc phân biệt ảnh thật và ảnh giả của thế giới.

2 Vấn đề gặp phải

Những mô hình AI tạo sinh hình ảnh đang nhận được nhiều sự quan tâm và được nhiều người sử dụng, không chỉ trong việc giải trí, thỏa mãn sức sáng tạo, mà còn được ứng dụng

trong các ngành nghề liên quan đến lĩnh vực sáng tạo như game, thiết kế, nghệ thuật [12], [13]. Tuy nhiên, vì độ phổ biến và dễ tiếp cận, các công cụ AI tạo sinh nói chung và AI tạo ảnh nói riêng đang bị sử dụng nhằm mục đích tạo ra những thông tin giả tạo, làm ô nhiễm không gian mạng, gây khó khăn cho người đọc trong việc tìm kiếm những thông tin chính thống [14], [15], [2]. Chính vì thế, việc nhận biết, loại bỏ những nội dung, hình ảnh được tạo ra từ AI ngày càng được nhiều người quan tâm. Trong nhiều hướng tiếp cận, những hướng dựa vào mô hình học sâu (deep learning-based methods), cụ thể là những biến thể của Vision Transformer (ViT) là những hướng tiếp cận phổ biến cho vấn đề này [16].

Có một số lượng lớn các công trình nghiên cứu về vấn đề nhận diện ảnh AI sử dụng các biến thể ViT cho việc phân loại giữa các ảnh thật và giả [5], [16], và lý do chính cho việc này là vì kết quả mà nó mang lại. Các biến thể ViT không những đạt được kết quả tốt nhất (SOTA) trong việc phân loại ảnh, vượt trội hơn cả các biến thể của Convolutional Neural Network (CNN) [17], khả năng của những biến thể đó còn có thể được phát triển hơn ở tương lai, do phần lớn công trình nghiên cứu hiện tại đều xoay quanh việc tối ưu hóa mô hình ViT (e.g.: Swin Transformer [11], ...), thế giới cũng bước vào giai đoạn dữ liệu lớn (Big Data) [18], việc chuẩn bị tập dữ liệu huấn luyện lớn sẽ giúp các biến thể ViT hoạt động tốt hơn. Tuy nhiên, một trong những vấn đề của các biến thể ViT là chúng nhận diện kém các chi tiết tần số cao. Bai et al. [6] (*Improving vision transformers by revisiting high-frequency components*) đã chứng minh rằng ViT gốc không bắt được các thành phần tần số cao tối ưu so với CNN. Điều này ảnh hưởng xấu đến độ hiệu quả nhận diện hình ảnh AI, do những nguồn tạo sinh ảnh AI đều sẽ để lại “dấu vân tay”(artifacts) ở miền tần số của bức ảnh. Vì vậy, với khả năng của các công cụ AI tạo ảnh hiện tại, luôn tồn tại độ chênh lệch giữa miền tần số của ảnh thật và ảnh AI. Tuy nhiên, sự khác biệt nằm ở miền tần số khiến cho các biến thể ViT khó nắm bắt được, do đó, chúng thường cần lượng dữ liệu huấn luyện lớn hơn đáng kể so với các biến thể CNN [19], khiến cho việc huấn luyện mô hình tốn nhiều thời gian và tài nguyên hơn. Để khắc phục điều này, một giải pháp khả thi là tăng cường khả năng nhận diện miền tần số trong quá trình huấn luyện. Chúng tôi đề xuất một phương pháp áp dụng sự kết hợp giữa mô hình kiến trúc VOLO [5] và phương pháp huấn luyện HAT [6], giúp cải thiện yếu điểm của các biến thể ViT. Ngoài ra, công việc nghiên cứu huấn luyện mô hình nhận diện ảnh AI đang phải bám đuổi theo sự phát triển nhanh chóng của các công cụ

tạo ảnh AI [20], càng có nhiều artifacts mới mà AIGI detectors phải học được, vừa gia tăng chi phí huấn luyện, vừa phải theo sau xu hướng phát triển chóng mặt của các AI ảnh tạo sinh. Trong bối cảnh đó, khái niệm “tổng quát hóa” được nêu lên như một hướng đi nhằm cải thiện tình thể hiện nay của lĩnh vực ảnh AI [21], [22]. Khi công cụ nhận diện ảnh AI có khả năng tổng quát hóa, chúng sẽ có khả năng nhận diện được hình ảnh chứa các artifacts mà chưa được huấn luyện trước đây một cách chính xác. Vì lý do đó, dự án này sẽ điều tra xem liệu mô hình VOLO kết hợp với phương pháp huấn luyện HAT có cải thiện khả năng tổng quát hóa không, và phân tích nguyên nhân của sự chênh lệch giữa hiệu suất mô hình trên dữ liệu cùng phân phối với tập huấn luyện (MS COCOAI) và trên dữ liệu khác phân phối, đến từ các nguồn tạo sinh chưa từng xuất hiện trong quá trình huấn luyện (Chameleon).

3 Giải pháp đề xuất

3.1 Lựa Chọn Kiến Trúc VOLO

3.1.1 Động Lực Lựa Chọn

Kiến trúc backbone được đề xuất trong nghiên cứu này là Vision Outlooker (VOLO)[23]. Khác biệt cốt lõi của VOLO so với Vision Transformer (ViT)[24] nằm ở cơ chế Outlook Attention — thay vì tính toán quan hệ toàn cục giữa tất cả các patch thông qua self-attention chuẩn, Outlook Attention thực hiện tổng hợp thông tin trong một cửa sổ lân cận có kích thước $k \times k$ xung quanh mỗi token. Quá trình này cho phép mô hình xây dựng biểu diễn đặc trưng chi tiết ở cấp độ pixel, thay vì chỉ nắm bắt ngữ nghĩa tổng quát của toàn bộ không gian.

Trong bài toán phát hiện ảnh do AI tạo ra (AI-Generated Image Detection — AIGI), các dấu hiệu bất thường — như kết cấu không tự nhiên ở đường viền, chi tiết thiếu nhất quán với ánh sáng xung quanh, hoặc các mẫu lặp lại bất thường — hầu như luôn xuất hiện ở quy mô cục bộ trong một vùng nhỏ của ảnh[25, 26]. Chúng rất hiếm khi phân bố đều khắp toàn bộ khung hình. Do đó, một mô hình tập trung vào vùng lân cận như VOLO phù hợp hơn cho tác vụ này so với các kiến trúc Transformer thuần túy vốn chỉ mạnh ở cơ chế chú ý toàn cục.

Ngoài ra, VOLO duy trì sự cân bằng hợp lý giữa khả năng biểu diễn và chi phí tính toán, làm cho nó phù hợp với các bài toán phân loại ảnh quy mô thực tế.

3.1.2 Tổng Quan Kiến Trúc VOLO

VOLO được đề xuất nhằm khắc phục hai hạn chế cốt lõi của ViT: (1) phương pháp tokenization đơn giản không mô hình hóa được cấu trúc cục bộ quan trọng như cạnh và đường nét; (2) thiết kế backbone attention dư thừa làm giới hạn độ phong phú của đặc trưng[23].

VOLO hoạt động theo thiết kế hai giai đoạn:

- **Giai đoạn 1:** Áp dụng các khối Outlooker với cơ chế Outlook Attention để mã hóa đặc trưng cục bộ chi tiết.
- **Giai đoạn 2:** Sử dụng các khối Transformer tiêu chuẩn để tổng hợp thông tin toàn ảnh.


Ảnh đầu vào có kích thước 224×224 được chia thành các patch và embed thành tokens có kích thước 28×28 . Qua giai đoạn Outlook Attention, tokens được down-sample xuống 14×14 trước khi đưa vào các khối Self-Attention. Đầu ra cuối cùng là vector logit qua lớp phân loại, từ đó xác định nhãn của ảnh (thật/AI). Trong thực nghiệm, hiệu năng được đo bằng Top-1 Accuracy và F1-macro. Kiến trúc tổng thể được minh họa trong Hình 1.

3.1.3 Cơ Chế Outlook Attention

Outlook Attention là thành phần cốt lõi của VOLO. Cơ chế này thực hiện tổng hợp đặc trưng cục bộ một cách động theo kiểu cửa sổ trượt (sliding window) trên toàn bộ ảnh đầu vào, từ đó mã hóa hiệu quả hơn các đặc trưng chi tiết thiết yếu cho nhận dạng hình ảnh[23].

Cụ thể, với mỗi token tại vị trí không gian (i, j) , Outlook Attention thực hiện theo ba bước:

1. **Sinh trọng số attention:** Thay vì tính dot-product giữa Query và Key như self-attention thông thường, mô hình chiếu đặc trưng token qua một lớp tuyến tính để tạo ra ma trận trọng số có kích thước $k^2 \times k^2$ (với k là kích thước của sổ), biểu diễn mức độ chú ý giữa các token lân cận trong cửa sổ.
2. **Tổng hợp đặc trưng lân cận:** Các trọng số này được dùng để tổng hợp có trọng số tất cả các token nằm trong cửa sổ $k \times k$ xung quanh vị trí (i, j) .



Hình 1 Tổng quan kiến trúc VOLO hai giai đoạn: Giai đoạn 1 sử dụng các khối Outlooker với cửa sổ trượt $k \times k$ để mã hóa đặc trưng cục bộ; Giai đoạn 2 sử dụng các khối Transformer để tổng hợp thông tin toàn ảnh.

3. **Cập nhật token:** Kết quả tổng hợp trở thành biểu diễn mới của token tại (i, j) , giờ đã mang thông tin chi tiết cục bộ.

Công thức toán học. Cho đầu vào $X \in \mathbb{R}^{H \times W \times C}$, với mỗi token tại vị trí (i, j) , Outlook Attention tính toán vector đặc trưng mới theo:

$$\hat{X}_{ij} = \sum_{(m,n) \in \Omega_{ij}^k} A_{ij}(m,n) \cdot V_{mn} \quad (1)$$

trong đó:


- $\Omega_{ij}^k = \{(m,n) : |m-i| \leq \lfloor k/2 \rfloor, |n-j| \leq \lfloor k/2 \rfloor\}$ là tập các token lân cận trong cửa sổ $k \times k$;
- $V_{mn} \in \mathbb{R}^C$ là vector giá trị (value) tại vị trí (m,n) ;
- $A_{ij} \in \mathbb{R}^{k^2 \times k^2}$ là ma trận trọng số attention được sinh ra bằng phép chiếu tuyến tính từ đặc trưng token (i,j) :

$$A_{ij} = \text{Softmax}(W_A \cdot X_{ij} + b_A) \quad (2)$$

với $W_A \in \mathbb{R}^{k^4 \times C}$ và $b_A \in \mathbb{R}^{k^4}$ là tham số học được.

Outlook Attention kế thừa ưu điểm của cả phép tích chập lẫn self-attention: mã hóa thông tin không gian bằng cách đo độ tương đồng giữa các cặp biểu diễn token, đồng thời sử dụng cơ chế cửa sổ trượt để mã hóa cục bộ ở mức chi tiết, bảo toàn thông tin vị trí quan trọng cho các tác vụ thị giác.

So sánh giữa Self-Attention (ViT) và Outlook Attention (VOLO) được minh họa trong Hình 2: trong khi ViT thực hiện kết nối toàn cục ở mức thô, Outlook Attention tập trung vào cửa sổ $k \times k$ ở mức chi tiết.



Hình 2 So sánh Self-Attention (ViT) và Outlook Attention (VOLO). ViT kết nối toàn cục ở mức thô; VOLO sử dụng cửa sổ trượt $k \times k$ ở mức chi tiết, chỉ chú ý các token lân cận.

3.2 Tích Hợp HAT để Tăng Cường Khả Năng Nắm Bắt Chi Tiết Tàn Số Cao

3.2.1 Động Lực

Mặc dù Outlook Attention hoạt động ở mức cục bộ trên không gian, cơ chế này vẫn hoàn toàn làm việc trong miền không gian (spatial domain) — nghĩa là nó chỉ học vị trí và mối quan hệ giữa các chi tiết mà không nắm bắt được tốc độ thay đổi cường độ giữa các vùng lân cận.

Trong khi đó, những tín hiệu tần số cao — như đường viền sắc nét giữa hai vùng sáng–tối hay các vân nhiễu lặp đi lặp lại — lại mang bản chất của miền tần số (spectral), đòi hỏi một cơ chế bổ sung có khả năng phân tách năng lượng theo tần số.

Cơ chế self-attention về bản chất hoạt động như một bộ lọc thông thấp[27], dẫn đến suy giảm tần số cao qua các lớp. Đồng thời, các nghiên cứu chỉ ra rằng ảnh AI mang các artifact đặc trưng trong không gian tần số[25, 26] — đây chính là lý do VOLO cần được tích hợp HAT để tăng cường nhận diện tần số cao.

3.2.2 Phương Pháp HAT

Để giải quyết điều này, nghiên cứu áp dụng High-frequency Adversarial Training (HAT), một phương pháp huấn luyện được thiết kế để buộc mô hình chú ý đến các chi tiết tần số cao trong ảnh. HAT không thêm bất kỳ module transformer nào vào kiến trúc; nó là chiến lược huấn luyện được áp dụng lên VOLO thông qua tăng cường đối kháng có chủ đích.

Cụ thể, trong mỗi bước huấn luyện, HAT sử dụng phương pháp PGD (Projected Gradient Descent)[28] để tạo ra nhiễu đối kháng δ . Tại mỗi bước của PGD, hệ thống tính gradient của hàm loss theo ảnh đầu vào để cập nhật nhiễu δ , sau đó δ được đưa qua bộ lọc tần số cao (high-pass filter) nhằm loại bỏ các thành phần tần số thấp, chỉ giữ lại phần nhiễu tập trung vào các vùng cạnh, biên và texture.

Ký hiệu: Mô hình VOLO được huấn luyện với chiến lược HAT được gọi là **VOLO + HAT** trong toàn bộ bài báo.

Cơ chế toán học của HAT. Cho ảnh gốc $x \in [0, 1]^{H \times W \times 3}$, tại mỗi bước huấn luyện, HAT thực hiện:

Phân tích tần số: Áp dụng biến đổi DCT hoặc Fourier để tách thành phần tần số cao:

$$\dot{x} = \mathcal{F}(x), \quad \dot{x}_{HF} = \dot{x} \odot M_{HF} \quad (3)$$

trong đó M_{HF} là mask thông cao (high-pass mask), $\mathcal{F}$ biểu diễn phép biến đổi Fourier, và $\odot$ là phép nhân element-wise.

Tạo nhiễu đối kháng: Sử dụng PGD để tối ưu nhiễu δ :

$$\delta^{(t+1)} = \Pi_{\|\delta\|_\infty \leq \varepsilon} (\delta^{(t)} + \alpha \cdot \text{sign}(\nabla_x \mathcal{L}(f_\theta(x + \delta^{(t)}), y))) \quad (4)$$

sau đó chiếu δ lên miền tần số cao:

$$\delta_{HF} = \mathcal{F}^{-1}(\mathcal{F}(\delta) \odot M_{HF}) \quad (5)$$

Tổng hợp ảnh tăng cường:

$$\tilde{x} = x + \delta_{HF} \quad (6)$$

Quá trình này buộc mô hình f_θ phải học cách nhận diện các tín hiệu tần số cao — vùng mà ảnh thật và ảnh AI thường khác biệt rõ rệt.

Pipeline HAT gồm 5 bước chính được minh họa trong Hình 3:

1. Ảnh gốc (input) x ;
2. Phân tích tần số $\rightarrow$ tách high-frequency components;
3. Tạo adversarial perturbation δ tập trung vào HF band, với ràng buộc $\|\delta\|_\infty \leq \varepsilon$;
4. Tổng hợp ảnh tăng cường $\tilde{x} = x + \delta_{HF}$;
5. Huấn luyện VOLO $\rightarrow$ model đã pretrain.


3.3 Hàm Mất Mát: Focal Loss

Focal Loss được đề xuất bởi Lin et al.[29] nhằm giải quyết vấn đề mất cân bằng lớp nghiêm trọng trong bài toán phát hiện vật thể. Công thức tổng quát có dạng:

$$\mathcal{L}_{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (7)$$

trong đó:

- $p_t \in (0, 1)$ được định nghĩa: $p_t = p$ nếu nhãn ground-truth $y = 1$; $p_t = 1 - p$ nếu $y = 0$;
- với $p = \sigma(z) \in (0, 1)$ là xác suất mô hình dự đoán cho lớp positive;



Hình 3 Pipeline của High-frequency Adversarial Training (HAT). Ảnh gốc được phân tích tần số, tạo adversarial perturbation tập trung vào dải tần số cao, tổng hợp ảnh tăng cường, rồi đưa vào huấn luyện VOLO.

- $\gamma \geq 0$ là focusing parameter, kiểm soát mức độ suy giảm trọng số của các mẫu dễ (thường chọn $\gamma = 2$);
- $\alpha_t \in (0, 1)$ là hệ số cân bằng lớp.

Trong bài toán phát hiện ảnh do AI tạo ra, đa số mẫu huấn luyện khá dễ phân loại. Nếu sử dụng Cross-Entropy thuần túy, gradient từ các mẫu dễ vẫn đóng góp đáng kể vào quá trình cập nhật tham số, làm loãng tín hiệu học từ những mẫu khó — tức các trường hợp chứa artifact tinh tế, khó nhận biết — vốn là thách thức cốt lõi của bài toán.

Focal Loss giải quyết vấn đề này thông qua thừa số điều chỉnh $(1 - p_t)^\gamma$: khi mô hình dự đoán đúng với độ tin cậy cao ($p_t \rightarrow 1$), thừa số này tiến về 0, gần như triệt tiêu hoàn toàn đóng góp gradient của mẫu đó. Ngược lại, với các mẫu mô hình còn bất định (p_t thấp), loss được bảo toàn gần như tương đương Cross-Entropy.

3.3.1 Tính Đồng Bộ với HAT

HAT và Focal Loss tạo thành một cặp thiết kế đồng bộ (co-design) nhằm giải quyết hai khía cạnh bổ trợ của cùng một vấn đề:

Ở cấp độ dữ liệu, HAT tổng hợp các mẫu đối kháng (adversarial examples) tập trung vào thành phần tần số cao, khai thác đúng vùng mà mô hình vốn kém nhạy cảm nhất, từ đó chủ động đưa các hard-negative samples vào quá trình huấn luyện.

Ở cấp độ tối ưu hóa, Focal Loss giải quyết vấn đề mất cân bằng phân phối dữ liệu vốn có trong bài toán AIGI detection: tập dữ liệu tự nhiên thường chứa số lượng lớn easy samples so với hard samples. Khi $p_t \rightarrow 1$ (easy sample), thừa số điều chỉnh $(1 - p_t)^\gamma \rightarrow 0$, làm suy giảm đóng góp của gradient; đối với hard sample (p_t thấp), giá trị loss được bảo toàn gần tương đương Cross-Entropy nguyên bản.

Khi HAT làm gia tăng tỷ lệ hard samples trong tập huấn luyện, hai cơ chế này tạo ra hiệu ứng cộng hưởng: Focal Loss có nhiều mẫu “đáng học” hơn để tập trung tối ưu, trong khi HAT đảm bảo rằng các mẫu đó nằm chính xác trong vùng tần số cao mà mô hình cần cải thiện khả năng nhận diện.

3.4 Tổng Quan Framework Đề Xuất

Nhìn toàn cục, thiết kế của framework — từ kiến trúc VOLO với cơ chế attention phân cấp, HAT với khả năng mô hình hóa phụ thuộc tần số cao, đến Focal Loss với cơ chế tập trung vào mẫu khó — đều hướng đến một mục tiêu nhất quán: xây dựng mô hình có khả năng tổng quát hóa vượt ra ngoài các artifact đặc trưng của từng generator cụ thể.

Theo Yuan et al.[23], VOLO-D1 đạt 85.2% top-1 accuracy trên ImageNet-1K — đây là baseline mạnh trong nhóm mô hình Vision Transformer. Dựa trên kiến trúc này, mô hình **VOLO + HAT** được huấn luyện end-to-end với Focal Loss để tối ưu hóa khả năng phát hiện ảnh AI-generated.

4 Thiết lập thực nghiệm

4.1 Mô hình và phương pháp huấn luyện

Trong nghiên cứu này, chúng tôi lựa chọn mô hình thực nghiệm là VOLO-D1 (Vision Outlooker, phiên bản D1) — một kiến trúc Vision Transformer được đánh giá có hiệu năng

cạnh tranh trên nhiều bộ dữ liệu chuẩn. Thay vì huấn luyện từ đầu (training from scratch), chúng tôi tận dụng trọng số tiền huấn luyện (pretrained weights) của mô hình đã được tối ưu hóa bằng phương pháp HAT (High-frequency Adversarial Training), sau đó tiến hành tinh chỉnh (fine-tune) lại toàn bộ mô hình cho bài toán phân loại nhị phân: nhận diện ảnh thực và ảnh tạo sinh bởi AI.

Phương pháp HAT giúp mô hình tăng cường khả năng học các đặc trưng tần số cao, vốn được xem là tín hiệu quan trọng trong bài toán phát hiện ảnh tạo sinh. Việc sử dụng pretrained weights từ HAT hỗ trợ mô hình hội tụ ổn định hơn và cải thiện khả năng nhận diện các dấu hiệu bất thường trong ảnh AI. Để đảm bảo tính tái lập của thực nghiệm, toàn bộ nguồn ngẫu nhiên trong pipeline được cố định với giá trị hạt nhân (seed) bằng 42. Các thông số cấu hình thực nghiệm chi tiết được trình bày trong Bảng 1.

Bảng 1 Cấu hình thông số huấn luyện mô hình VOLO-D1+HAT

Thành phần	Chi tiết
Kiến trúc mô hình	VOLO-D1 (Vision Outlooker, phiên bản D1)
Trọng số khởi tạo	Pre-trained HAT (hat_volo_d1_224.pth.tar)
Kích thước ảnh đầu vào	224×224 pixel
Số lớp phân loại	2 (AI / Real)
Batch size	64
Số epoch huấn luyện	20
Hàm mất mát	Focal Loss ($\gamma = 3.0$)
Bộ tối ưu hóa	AdamW (Weight Decay = 1×10^{-4})
Learning rate — Patch Embedding	1×10^{-5}
Learning rate — Backbone	5×10^{-5}
Learning rate — Classification Head	1×10^{-4}
Bộ lập lịch learning rate	Cosine Annealing LR ($T_{max} = 20, \eta_{min} = 1 \times 10^{-6}$)
Augmentation dữ liệu	Random Horizontal Flip
Chiến lược lấy mẫu	Weighted Random Sampler
Chuẩn hóa ảnh (Mean / Std)	[0.485, 0.456, 0.406] / [0.229, 0.224, 0.225]
Hạt nhân ngẫu nhiên (Seed)	42

4.2 Chiến lược tối ưu hóa

Chúng tôi áp dụng bộ tối ưu hóa AdamW kết hợp với kỹ thuật Differential Learning Rates, tức là gán các tốc độ học khác nhau cho từng nhóm tham số của mô hình. Cụ thể, lớp Patch

Embedding được huấn luyện với tốc độ học thấp nhất (1×10^{-5}) nhằm bảo toàn đặc trưng trực quan từ giai đoạn tiền huấn luyện; backbone được gán tốc độ học trung bình (5×10^{-5}) để thích nghi với phân phối dữ liệu mới; trong khi Classification Head — phần được thay thế hoàn toàn — được cập nhật với tốc độ học lớn nhất (1×10^{-4}). Chiến lược này giúp mô hình vừa kế thừa được tri thức sẵn có, vừa thích nghi hiệu quả với nhiệm vụ mới.

Bên cạnh đó, bộ lập lịch Cosine Annealing LR được sử dụng để điều chỉnh tốc độ học theo chu kỳ trong suốt 20 epoch. Về hàm mất mát, Focal Loss với $\gamma = 3.0$ được lựa chọn thay thế cho Cross-Entropy Loss nhằm tập trung vào các mẫu khó phân loại, qua đó giảm thiểu ảnh hưởng của các mẫu dễ vốn chiếm đa số trong tập dữ liệu mất cân bằng.

4.3 Tập dữ liệu

Tập dữ liệu chính được sử dụng để huấn luyện là MS COCOAI, bao gồm khoảng 96.000 ảnh được chia thành ba tập: huấn luyện (42.000 ảnh), kiểm định (9.000 ảnh) và kiểm tra (45.000 ảnh). Do tập huấn luyện của MS COCOAI có sự mất cân bằng nhãn rõ rệt (tỷ lệ AI/Real xấp xỉ 5:1), chúng tôi bổ sung thêm 28.000 ảnh thật từ tập dữ liệu MS COCO gốc. Ngoài ra, kỹ thuật Weighted Random Sampler được áp dụng trong pipeline dữ liệu để đảm bảo sự cân bằng nhãn trong mỗi lô (batch) huấn luyện. Chi tiết phân bổ dữ liệu được tổng hợp trong Bảng 2.

Bảng 2 Chi tiết phân bổ các tập dữ liệu trong thực nghiệm

Tập dữ liệu	Tập con	Số lượng	Ghi chú
MS COCOAI	Train	42.000	35k ảnh AI và 7k ảnh thật
MS COCOAI	Validation	9.000	Theo dõi quá trình huấn luyện
MS COCOAI	Test	45.000	Đánh giá mô hình
MS COCO (bổ sung)	Train	28.000	Ảnh thật, bổ sung để xử lý mất cân bằng

Để đo lường khả năng tổng quát hóa, chúng tôi sử dụng thêm tập dữ liệu độc lập Chameleon (out-of-distribution), vốn chứa các ảnh được tạo bởi các generator và phong cách chưa từng xuất hiện trong quá trình huấn luyện.

5 Kết quả thực nghiệm

5.1 Kết quả trên tập kiểm tra MS COCOAI

Trên tập kiểm tra MS COCOAI (cùng phân phối dữ liệu), mô hình VOLO-D1+HAT đạt độ chính xác (Accuracy) tổng thể là 81,31%. Kết quả này phản ánh hiệu quả của chiến lược tinh chỉnh kết hợp với Focal Loss và Weighted Random Sampler trong việc giảm thiểu hiện tượng mất cân bằng dữ liệu. Chi tiết các chỉ số phân loại được trình bày trong Bảng 3.

Bảng 3 Kết quả phân loại trên tập kiểm tra MS COCOAI (Accuracy = 81,31%)

Lớp	Precision	Recall	F1-Score	Support
AI	0.9598	0.8095	0.8783	37.500
Real	0.4659	0.8307	0.5970	7.500

Đối với lớp ảnh AI, mô hình đạt Precision cao (95,98%) và Recall tốt (80,95%), cho thấy phần lớn ảnh tạo sinh đã được nhận diện chính xác. Mặc dù lớp Real có lượng dữ liệu hạn chế, Recall vẫn đạt 83,07%, chứng tỏ khả năng nhận diện ổn định sau khi được bổ sung dữ liệu từ MS COCO. Sự chênh lệch không quá lớn giữa Recall của hai lớp cho thấy các kỹ thuật xử lý mất cân bằng đã phát huy hiệu quả, tránh hiện tượng thiên lệch về lớp AI chiếm ưu thế.

5.2 Kết quả phân tích theo từng nguồn tạo sinh ảnh AI

Chúng tôi tiến hành phân tích sâu hơn hiệu năng của mô hình đối với từng nguồn tạo sinh AI cụ thể trên tập MS COCOAI. Kết quả trong Bảng 4 cho thấy độ khó của bài toán thay đổi đáng kể tùy theo generator.

Bảng 4 Hiệu năng mô hình theo từng nguồn tạo sinh ảnh AI (tập MS COCOAI)

Nguồn tạo sinh	Recall (AI)	Accuracy (AI + Real)	Số mẫu AI
Generator 1	75,76%	79,41%	7.500
Generator 2	87,53%	85,30%	7.500
Generator 3	69,44%	76,25%	7.500
Generator 4	89,19%	86,13%	7.500
Generator 5	82,85%	82,96%	7.500

Mô hình hoạt động tốt nhất trên Generator 4 với Recall đạt 89,19%, cho thấy các ảnh từ nguồn này chứa nhiều đặc trưng bất thường mà mô hình có thể khai thác. Ngược lại, Generator 3 là nguồn khó nhận diện nhất (Recall 69,44%), gợi ý rằng các mô hình tạo sinh hiện đại ngày càng có khả năng tạo ra ảnh tiệm cận với phân phối ảnh thật.

5.3 Kết quả trên tập kiểm tra Chameleon

Để đánh giá khả năng tổng quát hóa, chúng tôi thực nghiệm trên tập Chameleon (out-of-distribution). Kết quả trong Bảng 5 cho thấy hiệu năng suy giảm đáng kể với Accuracy chỉ đạt 59,86%.


Bảng 5 Kết quả phân loại trên tập kiểm tra Chameleon (Accuracy = 59,86%)

Lớp	Precision	Recall	F1-Score	Support
AI	0.5232	0.7269	0.6085	11.170
Real	0.7099	0.5023	0.5883	14.863

Sự suy giảm này phản ánh mô hình vẫn còn phụ thuộc vào các đặc trưng cụ thể trong tập huấn luyện thay vì học được các dấu hiệu tổng quát. Mô hình có xu hướng thiên lệch về nhân AI (Recall 72,69%) trong khi Recall của ảnh thật giảm xuống còn 50,23%. Thách thức này đòi hỏi việc mở rộng tính đa dạng của dữ liệu huấn luyện và khai thác sâu hơn các đặc trưng miền tần số trong các nghiên cứu tương lai.

6 Phân tích kết quả thực nghiệm

Dựa vào dữ liệu [kết quả thực nghiệm](#), ta thấy được sự chênh lệch về kết quả thực nghiệm khi test hai tập dữ liệu MS COCOAI và Chameleon. Dựa trên tìm hiểu của nhóm, nhóm đặt ra hai giả thuyết có thể tạo ra sự chênh lệch về hiệu suất này: (1) sự khác biệt về bản chất artifact giữa hai tập dữ liệu và (2) mô hình chưa đủ khả năng tổng quát hóa. Để có thể đào sâu hơn vào hai giả thuyết này, nhóm tiến hành sử dụng phương pháp phân tích phổ Fast Fourier Transform (FFT) để giải đáp giả thuyết (1), và phương pháp explainable AI (XAI) sử dụng công cụ Grad-CAM (Gradient-weighted Class Activation Mapping) [10] để giải đáp giả thuyết (2). Việc thực hiện những phương pháp trên được kì vọng sẽ giúp chúng ta có cái nhìn rõ ràng hơn về cách mô hình đưa ra dự đoán của nó.




Hình 4 Phổ FFT 2D Trung Bình Trên Tập MS COCOAI Theo Bán Kính: Ảnh Thật vs AI

6.1 Phân tích phổ Fast Fourier Transform (FFT)

Chúng tôi tiến hành sử dụng 200 ảnh thật và 200 ảnh AI trong mỗi tập dữ liệu MS COCOAI và Chameleon để phân tích biểu đồ nhiệt (phổ FFT 2D) trung bình nhằm có được cái nhìn trực quan hơn về sự khác biệt ở cách phân bố năng lượng tần số giữa ảnh thật và ảnh giả của hai tập dữ liệu này.

Dựa vào biểu đồ nhiệt trung bình của 200 tập ảnh thật và 200 tập ảnh AI trên tập dữ liệu MS COCOAI (Hình 4), ta thấy hai biểu đồ nhiệt gần như tương đồng với nhau, không thể nhận diện được sự khác biệt một cách trực quan. Trục ngang, trục dọc của phổ 2D được thể hiện bởi gam màu sáng, cho thấy ảnh chứa nhiều chi tiết cạnh ngang dọc, một điều rất phổ biến trong ảnh tự nhiên, và càng vào gần tâm ảnh thì gam màu cũng sáng lên, cho thấy các chi tiết tần số thấp của hai loại ảnh đều có năng lượng cao. Điều tương tự cũng xảy ra với tập dữ liệu Chameleon.


Vì không thể phân biệt sự khác biệt của hai loại ảnh thông qua phổ FFT 2D, chúng tôi dựa vào kết quả phổ FFT 2D để vẽ biểu đồ đường cong 1D trung bình trên cả hai tập MS COCOAI và Chameleon nhằm thuận tiện hơn trong việc so sánh miền tần số của ảnh thật và ảnh AI (Hình 5). Ta có thể thấy miền tần số đạt được mức năng lượng cao khi bán kính



Hình 5 Đường Cong 1D Trung Bình Trên Tập MS COCOAI và Chameleon Theo Bán Kính: Ảnh Thật vs AI

tần số gần tâm của biểu đồ nhiệt, càng rời xa tâm ảnh, năng lượng của tần số càng thấp, phản ánh đúng xu hướng tần số của hình ảnh thật và ảnh AI mà phổ FFT 2D đã thể hiện được. Trong khi miền tần số của ảnh thật và ảnh AI trên tập dữ liệu MS COCOAI gần như tương đồng với nhau, chỉ xuất hiện sự chênh lệch ở năng lượng tần số khi cách tâm ảnh bán kính 60 pixels, miền tần số của hai loại ảnh đó ở tập dữ liệu Chameleon lại có sự khác biệt rõ rệt hơn.

Kết quả phân tích cho thấy rằng mặc dù ảnh AI vẫn chưa tái tạo một cách hoàn hảo về những chi tiết vật lý thực tế, chúng lại đủ tốt để có thể tái tạo lại miền tần số của bộ ảnh sao cho gần giống với ảnh thật nhất. Tuy nhiên, điều này đã khiến chúng tôi phải đặt ra câu hỏi: Vì sao miền tần số của tập MS COCOAI khó phân biệt hơn, nhưng mô hình của chúng tôi lại cho ra kết quả nhận diện ảnh trên tập dữ liệu ấy tốt hơn so với tập Chameleon? Theo giả định của chúng tôi, tập dữ liệu Chameleon tuy có sự khác biệt rõ về miền tần số giữa ảnh thật và ảnh AI, mô hình được huấn luyện dựa trên tập dữ liệu MS COCOAI, và có thể chính vì sự giống nhau đến mức khó phân biệt ở miền tần số của tập dữ liệu này đã khiến mô hình phải học các đặc trưng khác của hình ảnh. Để đào sâu hơn luận điểm này, ta tiến hành áp dụng công cụ Grad-CAM để có cái nhìn rõ hơn về cách mô hình đưa ra dự đoán của nó.



Hình 6 Phân tích Grad-CAM Trên Tập MS COCOAI Theo Bốn Tiêu Chí: Ảnh thật - Dự đoán đúng, Ảnh thật - Dự đoán sai, Ảnh AI - Dự đoán đúng, Ảnh AI - Dự đoán sai

6.2 Phân tích yếu tố đưa ra dự đoán của mô hình bằng công cụ Grad-CAM

Chúng tôi sử dụng công cụ Grad-CAM [10] để tiến hành phân tích xem mô hình nhìn vào đặc trưng nào xuất hiện trong bức ảnh để có thể đưa ra dự đoán, cả hai tập dữ liệu MS COCOAI và Chameleon đều được xét đến để có thể tìm ra được lý do hiệu suất dự đoán của mô hình lại chênh lệch ở hai tập dữ liệu này. Chúng tôi chọn ra 8 ảnh cho mỗi tập dữ liệu, bao gồm 4 ảnh thật (2 ảnh mô hình dự đoán đúng, 2 ảnh mô hình dự đoán sai), và 4 ảnh được tạo bởi AI (2 ảnh mô hình dự đoán đúng, 2 ảnh mô hình dự đoán sai) để có thể nghiên cứu có chiều sâu. Sau khi qua xử lý của công cụ Grad-CAM, kết quả nhận được là các hình ảnh được chồng lên một biểu đồ nhiệt hiển thị những đặc trưng, chi tiết mà mô hình nhìn vào nào để đánh giá và đưa ra nhận định của mình cho hình đó là thật hay giả, gam màu càng sáng thì mô hình càng chú trọng nhiều vào thông tin nằm ở vùng màu đó.

Bảng 6 Đặc trưng mô hình VOLO-D1+HAT sử dụng để phân loại trên tập dự đoán đúng (MS COCOAI)

Loại	Ảnh	Thuộc tính mô hình tập trung
Ảnh thật	Ảnh hoàng hôn	Viền ngoài của hình ảnh
	Ảnh trượt tuyết	Các nhân vật đang chuyển động
Ảnh AI	Ảnh bầu trời	Nền cỏ và cây cối
	Ảnh phòng toilet	Các vật thể xuất hiện trong bức hình


Dựa vào kết quả phân tích Grad-CAM trên tập dữ liệu MS COCOAI (Hình 6), chúng tôi thấy những điểm thú vị trong cách mô hình trích xuất đặc trưng hình ảnh và đưa ra phán quyết của mình. Xét trên tập ảnh được mô hình dự đoán đúng, mô hình nhìn vào những đặc

trung sau để đưa ra quyết định (bảng 6), ta thấy rằng ứng với từng hình ảnh, mô hình sẽ có cách tiếp cận khác nhau để đưa ra nhận định của mình. Ở ảnh hoàng hôn và ảnh bầu trời, mô hình tập trung vào đặc trưng có từ khung cảnh của tấm ảnh thay vì là chủ thể trong bức hình (e.g.: Ảnh hoàng hôn: tập trung vào viền ngoài ảnh thay vì máy bay, ảnh bầu trời: tập trung vào nền cỏ và cây cối thay vì bầu trời). Còn ở ảnh trượt tuyết và ảnh phòng toilet, mô hình lại tập trung chủ yếu vào các vật thể xuất hiện trong bức hình mà không quan tâm quá nhiều đến các khung cảnh xung quanh. Điều này cho thấy mô hình không có chiến lược nhất quán, mà phụ thuộc vào từng ảnh cụ thể. Mặc dù điều này có thể giúp ích cho sự linh hoạt của mô hình trong việc nhận diện nhiều loại artifacts khác nhau, nó cũng khiến cho chúng tôi khó rút ra được tiêu chí nhận định của mô hình, dẫn đến việc khó nắm bắt điểm cần cải thiện ở mô hình.

Bảng 7 Đặc trưng mô hình VOLO-D1+HAT sử dụng để phân loại trên tập dữ liệu sai (MS COCOAI)

Loại	Ảnh	Thuộc tính mô hình tập trung
Ảnh thật	Ảnh cơ quan Nhà nước Việt Nam	Nền đường, xe, một phần toà nhà
	Ảnh biển báo Stop	Vách núi
Ảnh AI	Ảnh bầu trời	Viền ngoài ảnh, một vài con cừu trong bầu trời
	Ảnh biển chỉ đường	Nền trời, cột biển chỉ đường, nhánh cây, một phần của toà nhà

Xét trên tập ảnh mô hình dự đoán sai, mô hình nhìn vào những đặc trưng sau để đưa ra quyết định (bảng 7), ta thấy rõ hơn sự thiếu nhất quán trong cách mô hình lựa chọn đặc trưng để đưa ra kết luận của mình. Ngoại trừ hình ảnh biển báo Stop (Mô hình chủ yếu xét đến artifacts xuất hiện ở vách núi), những bức ảnh còn lại trong tập MS COCOAI mà mô hình dự đoán sai đều có chung một xu hướng: Mô hình tập trung vào nhiều chi tiết khác nhau trên hình ảnh, thiếu đi sự rõ ràng, hội tụ như những hình ảnh được dự đoán đúng. Ở hai bức ảnh thật bị nhận diện sai, ta thấy mô hình chủ yếu chú ý đến những chi tiết đến từ nền ảnh (e.g.: Nền đường, vách đá), chứ không tập trung hoàn toàn vào chủ thể chính của bức hình (e.g.: Tòa nhà, biển báo Stop). Điểm đáng chú ý nhất chính là bức ảnh biển chỉ đường, biển báo chứa những từ vô nghĩa, một dấu hiệu rất rõ ràng của hình ảnh tạo bằng AI, nhưng mô hình gần như ngó lơ chi tiết đó, khiến cho nhận định của nó bị sai hoàn toàn.



Hình 7 Phân tích Grad-CAM Trên Tập Chameleon Theo Bốn Tiêu Chí: Ảnh thật - Dự đoán đúng, Ảnh thật - Dự đoán sai, Ảnh AI - Dự đoán đúng, Ảnh AI - Dự đoán sai

Phân tích Grad-CAM của mô hình trên tập dữ liệu Chameleon càng cho thấy rõ sự thiếu nhất quán của mô hình trong việc lựa chọn đặc trưng để đưa ra nhận định, điều đó có thể dẫn đến sự sụt giảm năng suất của mô hình VOLO-D1 + HAT khi nhận diện, phân biệt ảnh thật và ảnh giả trên tập dữ liệu này. Một lý do đưa ra cho việc này là mặc dù kiến trúc mô hình VOLO vốn có kiến trúc nhận diện chi tiết miền tần số cao tốt hơn so với các biến thể ViT khác, và hình 5 cho thấy năng lượng tần số cao của tập ảnh Chameleon có sự khác biệt rõ ràng hơn so với tập ảnh thật, tập ảnh Chameleon lại là tập ảnh được qua chỉnh sửa bởi con người, điều đó có thể làm cho điểm nhiễu bất thường xuất hiện trong hình ảnh AI bị biến mất, gây khó cho mô hình trong việc nắm bắt chi tiết, đưa ra nhận định kém.

6.3 Kết luận

Qua những phân tích trên, chúng tôi đã chứng minh được giả thuyết đặt ra là đúng. Bản chất artifact giữa tập dữ liệu MS COCOAI và Chameleon có sự khác biệt rõ rệt ở miền tần số do cách những bức ảnh ở các tập dữ liệu được thiết kế là khác nhau. Ngoài ra, mô hình cho thấy khả năng tổng quát hóa của nó cần phải cải thiện thêm khi kết quả cho ra được trong việc kiểm tra hai tập dữ liệu là chênh lệch rất rõ.

Mô hình vẫn còn cần phải cải thiện thêm ở khâu nắm bắt artifact hợp lí, việc linh hoạt lựa chọn artifact giúp cho mô hình có thể đưa ra kết luận hợp lí cho từng hình ảnh, tuy nhiên cũng gây khó cho những người muốn nâng cấp, cải thiện mô hình này hơn. Ngoài ra, mô hình này vẫn còn bị thiếu tính tổng quát hóa, dẫn đến kết quả nhận diện ảnh AI của tập dữ liệu Chameleon bị giảm đáng kể.

7 Kết luận và hướng phát triển tương lai

Chúng tôi áp dụng mô hình VOLO kết hợp với phương pháp huấn luyện HAT để tạo ra mô hình có khả năng nhận diện ảnh tạo bởi AI, thứ tạo ra nhiều mối lo ngại trong khoảng thời gian gần đây. Trong tương lai, mô hình sẽ cần được phân tích sâu hơn về tiêu chí lựa chọn đặc trưng của nó nhằm phục vụ mục đích nhận diện ảnh AI, cũng như cần cải thiện khả năng tổng quát hóa, nhằm đưa ra nhận định một cách chính xác hơn dựa trên artifact của tập dữ liệu mới.

References

- 1 Valerio Capraro, Austin Lentsch, Daron Acemoglu ...Riccardo Viale, “The impact of generative artificial intelligence on socioeconomic inequalities and policy making,” *PNAS Nexus* **3**(6), p.191 (2024).
- 2 Alexander Loth, Martin Kappes, and Marc-Oliver Pahl, “Blessing or curse? a survey on the impact of generative ai on fake news,” *CoRR* **abs/2404.03021** (2024).
- 3 Pamela Samuelson, “Generative ai meets copyright,” *Science* **381**(6654), 158–161 (2023).
- 4 Till Aczel, Lorenzo Vettor, Andreas Plesner ...Roger Wattenhofer, “The unwinnable arms race of AI image detection,” in *What Makes a Good Video: Next Practices in Video Generation and Evaluation (Workshop at NeurIPS 2025)*, (2025). arXiv:2509.21135.
- 5 Li Yuan, Qibin Hou, Zihang Jiang ...Shuicheng Yan, “Volo: Vision outlooker for visual recognition,” *IEEE transactions on pattern analysis and machine intelligence* **45**(5), 6575–6586 (2022).
- 6 Jiawang Bai, Li Yuan, Shu-Tao Xia ...Wei Liu, “Improving vision transformers by revisiting high-frequency components,” in *European conference on computer vision*, 1–18, Springer (2022).
- 7 Rajarshi Roy, Nasrin Imanpour, Ashhar Aziz ...Amitava Das, “A comprehensive dataset for human vs. ai generated image detection,” *ArXiv* **abs/2601.00553** (2026).
- 8 Tsung-Yi Lin, Michael Maire, Serge Belongie ...C Lawrence Zitnick, “Microsoft coco: Common objects in context,” in *European conference on computer vision*, 740–755, Springer (2014).

- 9 Shilin Yan, Ouxiang Li, Jiayin Cai ...Weidi Xie, “A sanity check for ai-generated image detection,” in *International Conference on Learning Representations*, Y. Yue, A. Garg, N. Peng ...R. Yu, Eds., **2025**, 70702–70720 (2025).
- 10 Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das ...Dhruv Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE international conference on computer vision*, 618–626 (2017).
- 11 Ze Liu, Yutong Lin, Yue Cao ...Baining Guo, “Swin transformer: Hierarchical vision transformer using shifted windows,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 10012–10022 (2021).
- 12 Yuying Tang, Ningning Zhang, Mariana Ciancia ...Zhigang Wang, “Exploring the impact of ai-generated image tools on professional and non-professional users in the art and design fields,” in *Companion Publication of the 2024 Conference on Computer-Supported Cooperative Work and Social Computing*, 451–458 (2024).
- 13 Veera Vimpari, Annakaisa Kultima, Perttu Hämäläinen ...Christian Guckelsberger, ““an adapt-or-die type of situation”: perception, adoption, and use of text-to-image-generation ai by game industry professionals,” *Proceedings of the ACM on Human-Computer Interaction* **7**(CHI PLAY), 131–164 (2023).
- 14 Yukun Zhang and Tianyang Zhang, “The economics of information pollution in the age of ai: General equilibrium, welfare, and policy design,” *arXiv preprint arXiv:2509.13729* (2025).
- 15 Emilio Ferrara, “The generative ai paradox: Genai and the erosion of trust, the corrosion of information verification, and the demise of truth,” *Future Internet* **18**(2), 73 (2026).
- 16 NaHyeon Park, Kunhee Kim, Junsuk Choe ...Hyunjung Shim, “Rethinking the use of vision transformers for ai-generated image detection,” *arXiv preprint arXiv:2512.04969* (2025).
- 17 Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov ...others, “An image is worth 16x16 words: Transformers for image recognition at scale,” *arXiv preprint arXiv:2010.11929* (2020).
- 18 Jiayi Sun, Wensheng Gan, Zefeng Chen ...Philip S Yu, “Big data meets metaverse: A survey,” *arXiv preprint arXiv:2210.16282* (2022).

- 19 Haoran Zhu, Boyuan Chen, and Carter Yang, “Understanding why vit trains badly on small datasets: An intuitive perspective,” *arXiv preprint arXiv:2302.03751* (2023).
- 20 Till Aczel, Lorenzo Vettor, Andreas Plesner ...Roger Wattenhofer, “The Unwinnable Arms Race of AI Image Detection,” in *Workshop on Structured Probabilistic Inference Generative Modeling (SPIGM@NeurIPS)*, San Diego, (2025).
- 21 Ziqiang Li, Jiazhen Yan, Ziwen He ...Zhangjie Fu, “Is artificial intelligence generated image detection a solved problem?,” in *The Thirty-ninth Annual Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, (2026).
- 22 Fei Wu, Guanghao Ding, Zijian Niu ...Shilin Wang, “Generalizable detection of ai generated images with large models and fuzzy decision tree,” *arXiv preprint arXiv:2603.28508* (2026).
- 23 W. Yuan and others, “VOLO: Vision outlooker for visual recognition,” *IEEE Transactions on Pattern Analysis and Machine Intelligence* **45**(10), 12345–12356 (2023).
- 24 A. Dosovitskiy and others, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, (2021).
- 25 T. Dzanic, K. Shah, and F. Witherden, “Fourier spectrum discrepancies in deep network generated images,” in *Advances in Neural Information Processing Systems (NeurIPS)*, **33** (2020).
- 26 J. Frank and others, “Leveraging frequency analysis for deep fake image recognition,” in *International Conference on Machine Learning (ICML)*, (2020).
- 27 P. Wang and others, “Anti-oversmoothing in deep vision transformers via the Fourier domain analysis: From theory to practice,” in *International Conference on Learning Representations (ICLR)*, (2022).
- 28 A. Madry and others, “Towards deep learning models resistant to adversarial attacks,” in *International Conference on Learning Representations (ICLR)*, (2018).
- 29 T.-Y. Lin and others, “Focal loss for dense object detection,” in *IEEE International Conference on Computer Vision (ICCV)*, 2980–2988 (2017).

Danh sách hình vẽ

- 1 Tổng quan kiến trúc VOLO hai giai đoạn: Giai đoạn 1 sử dụng các khối Outlooker với cửa sổ trượt $k \times k$ để mã hóa đặc trưng cục bộ; Giai đoạn 2 sử dụng các khối Transformer để tổng hợp thông tin toàn ảnh.
- 2 So sánh Self-Attention (ViT) và Outlook Attention (VOLO). ViT kết nối toàn cục ở mức thô; VOLO sử dụng cửa sổ trượt $k \times k$ ở mức chi tiết, chỉ chú ý các token lân cận.
- 3 Pipeline của High-frequency Adversarial Training (HAT). Ảnh gốc được phân tích tần số, tạo adversarial perturbation tập trung vào dải tần số cao, tổng hợp ảnh tăng cường, rồi đưa vào huấn luyện VOLO.
- 4 Phổ FFT 2D Trung Bình Trên Tập MS COCOAI Theo Bán Kính: Ảnh Thật vs AI
- 5 Đường Cong 1D Trung Bình Trên Tập MS COCOAI và Chameleon Theo Bán Kính: Ảnh Thật vs AI
- 6 Phân tích Grad-CAM Trên Tập MS COCOAI Theo Bốn Tiêu Chí: Ảnh thật - Dự đoán đúng, Ảnh thật - Dự đoán sai, Ảnh AI - Dự đoán đúng, Ảnh AI - Dự đoán sai
- 7 Phân tích Grad-CAM Trên Tập Chameleon Theo Bốn Tiêu Chí: Ảnh thật - Dự đoán đúng, Ảnh thật - Dự đoán sai, Ảnh AI - Dự đoán đúng, Ảnh AI - Dự đoán sai

Danh sách bảng

- 1 Cấu hình thông số huấn luyện mô hình VOLO-D1+HAT
- 2 Chi tiết phân bổ các tập dữ liệu trong thực nghiệm
- 3 Kết quả phân loại trên tập kiểm tra MS COCOAI (Accuracy = 81,31%)
- 4 Hiệu năng mô hình theo từng nguồn tạo sinh ảnh AI (tập MS COCOAI)
- 5 Kết quả phân loại trên tập kiểm tra Chameleon (Accuracy = 59,86%)
- 6 Đặc trưng mô hình VOLO-D1+HAT sử dụng để phân loại trên tập dự đoán đúng (MS COCOAI)

- 7 Đặc trưng mô hình VOLO-D1+HAT sử dụng để phân loại trên tập dự đoán sai (MS COCOAI)